

التنبؤ بسعر إغلاق الذهب يومياً وساعياً باستخدام تقنيات التعلم الآلي

وليم جادالله العودي، بشرى كمال محمد، مصطفى ابراهيم العلي، بلقيس لؤي غرز الدين، علي باسل علي.

الملخص يُعدّ الذهب أحد أبرز الأصول الاستثمارية وأكثرها استقراراً في الأسواق المالية العالمية، إذ يشكّل ملاذاً آمناً للمستثمرين في فترات الأزمات والاضطرابات الاقتصادية. وتزداد أهمية تحليل أسعار الذهب مع تعقيد المشهد المالي العالمي وتأثير العوامل المتشابكة عليه، كالعوامل الجيوسياسية، وتقلبات العملات، وأسعار الفائدة، ومؤشرات الأسهم. إن التنبؤ بسعر إغلاق الذهب يُعدّ من المسائل المعقدة في مجال تحليل السلاسل الزمنية، نظراً لوجود تذبذب عالي، وارتباط غير خطي مع مؤشرات متعددة، فضلاً عن وجود قيم مفقودة وتوزيعات غير متوازنة في البيانات. كما أن الدراسات السابقة غالباً ما اعتمدت على تردد زمني يومي أو شهري، في حين أن التردد الساعي يوفر دقة أكبر ومرونة في اتخاذ القرارات الاستثمارية قصيرة المدى.

تهدف هذه الدراسة إلى بناء نموذج تنبؤي فعال لتقدير سعر إغلاق الذهب بترددين مختلفين: يومياً وساعياً، وذلك باستخدام تقنيات تعلم آلي متقدمة. وتم دمج بيانات مالية واقتصادية من مصادر متعددة تشمل أسعار العملات، المؤشرات العالمية، المعادن الثمينة، وأسعار النفط، مع استخدام اشتقاقات فنية مثل المتوسطات المتحركة، مؤشرات القوة النسبية، وميزات التأخير الزمنية. ومن خلال مقارنة أداء عدة نماذج تعلم آلي، مثل XGBoost و ElasticNet و Linear Regression وغيرها، تسعى هذه الدراسة إلى تقديم إطار شامل يوازن بين الدقة والتفسير، ويخدم صنّاع القرار والمستثمرين في بناء استراتيجيات مبنية على التنبؤات الذكية.

الكلمات المفتاحية تنبؤ بأسعار الذهب، السلاسل الزمنية، التعلم الآلي، التردد اليومي، التردد الساعي، معالجة البيانات، اشتقاق الميزات، النماذج التنبؤية، تقييم النماذج.

1 المقدمة

تشهد أسعار الذهب تقلبات متواصلة ومتأثرة بعوامل عديدة اقتصادية وسياسية، مما يجعل التنبؤ بها أمراً بالغ الأهمية لصنّاع القرار والمستثمرين والباحثين في مجالات الاقتصاد والتمويل. ومع التطور المتسارع في تقنيات تحليل البيانات وتعلم الآلة، أصبح من الممكن استخدام هذه الأدوات الحديثة لبناء نماذج قادرة على التنبؤ بحركة أسعار الذهب [1] [4].

تكمن أهمية التنبؤ بأسعار الذهب في قدرته على عكس الحالة الاقتصادية العامة، حيث يُعدّ مؤشرًا لثقة المستثمرين واستقرار الأسواق. فعند تدهور العملات أو ارتفاع التضخم أو تصاعد التوترات الجيوسياسية، يرتفع الطلب على الذهب كمخزون للقيمة، مما يؤدي إلى تقلبات في سعره. وفي ظل العولمة المالية، باتت أسعار الذهب تتأثر بمجموعة واسعة من المتغيرات، مثل: مؤشرات الأسواق العالمية (S&P500, NASDAQ)، أسعار النفط والمعادن الأخرى، أسهم شركات التعدين، أسعار الفائدة، مؤشرات الدولار، التي بدأت ترتبط سلوكياً بسوق الذهب في بعض الفترات [10] [4].

وعلى الرغم من أن التنبؤ بأسعار الذهب جذب اهتماماً بحثياً واسعاً، إلا أن العديد من الدراسات السابقة ركّزت فقط على بيانات يومية أو شهرية، وغالباً ما اعتمدت على نماذج تقليدية مثل ARIMA أو الانحدار الخطي، والتي تفترض وجود علاقة خطية وثابتة بين المتغيرات، ما يجعلها محدودة القدرة على تمثيل العلاقات المعقدة والديناميكية الموجودة في الأسواق المالية الحقيقية [1] [4]. كما أن التردد الزمني الساعي، رغم أهميته المتزايدة في التداول عالي التردد وفي دعم القرارات اللحظية، لم يبل حظاً كافياً من التحليل في معظم الأبحاث السابقة [8] [5].

مع التقدم السريع في تقنيات تعلم الآلة (Machine Learning)، أصبح من الممكن التعامل مع مجموعات بيانات ضخمة ومعقدة، وتطبيق نماذج غير خطية تتكيف مع العلاقات المتغيرة بين العوامل. من بين أبرز هذه النماذج: خوارزمية XGBoost، الشبكات العصبية العميقة مثل LSTM، نماذج الانحدار المنتظم مثل ElasticNet، والغابات العشوائية Random Forest، والتي أثبتت فعاليتها في التنبؤ بالسلاسل الزمنية المالية ذات الطبيعة المعقدة [8] [7] [4] [2].

تأتي هذه الدراسة لتقديم نموذج تنبؤي متكامل لتقدير سعر إغلاق الذهب بترددين مختلفين: يومي وساعي، باستخدام مزيج من تقنيات التعلم الآلي المتقدمة. تم الاعتماد على مصادر بيانات موثوقة، شملت مؤشرات مالية عالمية (الأسواق، العملات، النفط، الفضة، الدولار، شركات التعدين)، إلى جانب اشتقاقات فنية وتقنية مثل المتوسطات المتحركة (SMA, EMA)، مؤشرات الزخم (RSI, MFI, ADX)، وميزات التأخير الزمني (Lag Features) [10] [7] [4]. وتم تصميم تجربة مقارنة بين عدد من النماذج من حيث الدقة والمرونة والتفسير.

يهدف هذا العمل إلى تطوير نموذج تنبؤي فعال وموثوق يساعد على فهم العوامل المؤثرة في سعر الذهب، ويخدم صنّاع القرار في المجالات المالية والاستثمارية، من خلال تقديم أداة دقيقة قابلة للاستخدام في التنبؤ قصير ومتوسط المدى، مع الحفاظ على توازن بين الأداء والتفسير.

2 مراجعة الأدبيات

حظيت مسألة التنبؤ بأسعار الذهب باهتمام واسع في الأدبيات الأكاديمية، نظرًا لأهميتها في دعم القرارات الاستثمارية والتخطيط المالي على المستويين الفردي والمؤسسي. ومع تزايد تعقيد الأسواق وتداخل العوامل المؤثرة، اتجهت العديد من الدراسات إلى استخدام تقنيات تعلم آلي متقدمة ونماذج هجينة لتعزيز دقة التنبؤ. يُستعرض في هذا القسم أبرز الأعمال السابقة التي تناولت هذا الموضوع، مع التركيز على البيانات المستخدمة، والنماذج المطبقة، والنتائج المتحققة.

2.1 استخدام النماذج الإحصائية وتقنيات التعلم التقليدية

تناولت بعض الدراسات المبكرة التنبؤ بأسعار الذهب باستخدام نماذج إحصائية مثل الانحدار الخطي ونموذج الانحدار الذاتي (ARIMA) على سبيل المثال، استخدم Sami و (2017) Junejo نماذج خطية وتقنيات الانحدار لتحليل تأثير مجموعة من المؤشرات الاقتصادية، مثل أسعار النفط، ومؤشرات الأسهم، ومعدلات الفائدة، على سعر الذهب، وخلصوا إلى وجود ارتباطات قوية بين هذه العوامل وسعر الذهب، لكنهم أشاروا إلى ضعف هذه النماذج في تمثيل العلاقات غير الخطية. [1]

2.2 تقنيات تعلم الآلة والنماذج غير الخطية

في السنوات الأخيرة، شهدت الأبحاث تحولًا ملحوظًا نحو استخدام تقنيات تعلم الآلة لما توفره من قدرة على التعامل مع البيانات المعقدة والمتغيرة. قدمت دراسة (Masud et al. (2025 مقارنة شاملة بين عدد من النماذج التنبؤية، شملت XGBoost، Random Forest، SVM، Prophet، و LSTM، بالاعتماد على بيانات يومية. وخلصت إلى أن النماذج القائمة على التعلم العميق مثل LSTM ونماذج التعزيز مثل XGBoost تفوقت من حيث الدقة في تمثيل الأنماط غير الخطية والطويلة الأجل [22]. كما أكدت دراسات أخرى على فعالية هذه النماذج في التعامل مع البيانات المالية المعقدة [4][8]

2.3 معالجة القيم المفقودة وتحسين جودة البيانات

أشارت دراسة (Alrawajfi et al. (2024 إلى أهمية جودة البيانات المدخلة في تحسين دقة النماذج، إذ قارنت بين عدة طرق لتعويض القيم المفقودة في بيانات أسعار الذهب، مثل KNN، الانحدار، والانحدار المعزز. وأظهرت الدراسة أن جودة التعويض تؤثر مباشرة على أداء النماذج التنبؤية، خاصة عند وجود أكثر من 30% من القيم المفقودة. [3]

2.4 المراجعات الشاملة واختيار النماذج الفعالة

استعرضت دراسة (Das et al. (2022 عددًا كبيرًا من الدراسات المنشورة خلال العقد الأخير حول تنبؤ أسعار الذهب، وأشارت إلى أن النماذج القائمة على دعم النواقل (SVM) والانحدار المعزز (Gradient Boosting) تُعد من أكثر النماذج فعالية في التعامل مع البيانات المالية المعقدة، خاصة عندما تكون مرتبطة بمتغيرات متعددة مثل العملات والأسواق والبورصات [4]. كما أضاف Weng et al. (2023 أن نماذج الشبكات العصبية يمكنها أيضًا التكيف مع التحركات السريعة في الأسعار بترددات عالية. [5]

2.5 الفجوة البحثية

على الرغم من تعدد الدراسات التي تناولت تنبؤ أسعار الذهب، إلا أن معظمها اقتصر على بيانات يومية أو شهرية، وتجاهل الترددات الزمنية الأدق (مثل البيانات الساعية) التي باتت مهمة في ظل التداول عالي التردد. [8][5] (High-Frequency Trading) كما أن بعض الدراسات ركزت على نموذج واحد دون إجراء مقارنة منهجية بين النماذج، أو أغفلت الاشتقاق الفني للميزات، مثل مؤشرات الزخم أو المتوسطات المتحركة، والتي تُعد عناصر حاسمة في تحسين دقة التنبؤ [7][10]

وبناءً على ما سبق، تسعى هذه الدراسة إلى استكمال جهود الدراسات السابقة من خلال اختبار عدد من نماذج التعلم الآلي، مثل Ridge، Lasso، و ElasticNet، مع التركيز على تحليل البيانات اليومية والساعية ودمج مؤشرات فنية متقدمة لم تُستخدم بالشكل الكافي في الدراسات السابقة. وعلى الرغم من أن دراسات متعددة مثل (Masud et al. (2025 و (Das et al. (2022 أظهرت تفوق نماذج معقدة مثل XGBoost و LSTM في التعامل مع بيانات الذهب [2][4][8]، إلا أن نتائج هذه الدراسة أظهرت خلاف ذلك، حيث تفوقت النماذج الخطية مثل Linear Regression و ElasticNet من حيث الأداء والثبات، خصوصًا في التردد الساعي. ويُعزى هذا التباين إلى طبيعة البيانات المعتمدة في هذه الدراسة، والتي احتوت على علاقات خطية واضحة ومستوى ضجيج مرتفع في البيانات اللحظية. كما أن النماذج المعززة قد تكون أكثر عرضة لفرط التعلم (Overfitting) في حال عدم توفر بيانات تدريب متوازنة، وهو ما لوحظ بوضوح في نماذج XGBoost عند اختبارها على التردد الساعي [6][9]. تؤكد هذه النتائج أهمية مراعاة بنية البيانات وتوزيعها الزمني عند اختيار النموذج المناسب، وتشير إلى أن النماذج الأبسط قد تكون أكثر فاعلية في بعض الحالات، خاصة في البيانات التي تتسم بالتذبذب العالي والوضوء اللحظي.

3 البيانات المستخدمة

اعتمدت هذه الدراسة على مجموعتين من البيانات الزمنية المتعلقة بسعر الذهب، تم جمعها بترددين مختلفين: تردد يومي وآخر ساعي، وذلك بهدف تحليل سلوك الذهب في سياقات زمنية متعددة، واختبار فعالية النماذج التنبؤية في كل حالة. تم الحصول على البيانات من منصة Yahoo Finance [11]، التي تُعد من أبرز المصادر المفتوحة للبيانات المالية الموثوقة. [5]

شملت البيانات اليومية لسعر الذهب الفترة الممتدة من يناير 2008 حتى ديسمبر 2024، وتضمنت المعلومات الأساسية لكل يوم مثل سعر الافتتاح، أعلى وأدنى سعر، سعر الإغلاق، وحجم التداول. وتمثل هذه البيانات مرجعًا مناسبًا لفهم الاتجاهات العامة والتغيرات الموسمية وطويلة الأجل في سعر الذهب. في المقابل، تم استخدام بيانات ساعية للذهب لتغطية الفترة من يناير 2023 حتى بداية شهر يوليو 2025، حيث تم جمع نقطة بيانات لكل ساعة، مما سمح برصد التذبذبات اللحظية والتغيرات قصيرة الأمد في السعر. وتُعد هذه البيانات ذات أهمية خاصة في تطبيقات التنبؤ المرتبطة بالتداول عالي التردد، حيث تتطلب النماذج استجابة دقيقة للتغيرات اللحظية [2][8]

ولتعزيز قدرة النماذج التنبؤية على التقاط الأنماط الحقيقية لسعر الذهب، تم دمج مجموعة من البيانات المالية والاقتصادية المرتبطة والمؤثرة فيه. شملت هذه البيانات أسعار صرف عدد من العملات الرئيسية مثل EUR/USD ، USD/JPY ، GBP/USD ، CNY/USD ، و INR/USD ، والتي تعكس التقلبات في قوة الدولار الأمريكي وتأثيرها المباشر على الذهب [4][10][12]. كما تم إدخال مؤشرات اقتصادية متنوعة مثل مؤشر الدولار الأمريكي (USDX) ، مؤشر تقلب السوق (VIX) ، و عوائد سندات الخزانة الأمريكية (US10Y) ، لما لها من تأثير مباشر على سلوك المستثمرين تجاه الأصول الآمنة مثل الذهب. [1]

بالإضافة إلى ذلك، تم دمج أسعار سلع مرتبطة مثل الفضة والبلاطين والنفط الخام WTI و Brent ، وذلك لإبراز العلاقة الهيكلية بين الذهب وبقية المعادن الثمينة والموارد الطبيعية [13]. كما تم الاستفادة من بيانات مؤشرات الأسهم العالمية مثل S&P500 ، NASDAQ ، DOW JONES ، FTSE ، DAX ، و NIKKEI ، حيث تعكس هذه المؤشرات الحالة العامة للأسواق وتستخدم كمؤشرات لإقبال المستثمرين على الأصول الآمنة [14][7]. علاوة على ذلك، أدرجت بيانات لأسهم بعض شركات تعدين الذهب الرائدة مثل Wheaton Precious Metals (WPM) ، Eldorado Gold (EGO) ، و Buenaventura (BVN) ، لما لها من ارتباط وثيق بمسار الذهب في الأسواق [15][10].

واجهت عملية بناء قاعدة البيانات عدداً من التحديات، من أبرزها وجود فجوات زمنية وعدم تطابق التواريخ بين مصادر البيانات، إضافة إلى القيم المفقودة الناتجة عن الإجازات الرسمية أو التوقيفات المؤقتة في بعض الأسواق. كذلك، استوجب اختلاف التردد الزمني بين المصادر إجراء عمليات توحيد (resampling) وتحويل جميع السلاسل الزمنية إلى نطاق زمني متناسق وفقاً لنوع النموذج (يومي أو ساعي). تم التعامل مع هذه التحديات باستخدام تقنيات تعويض القيم المفقودة مثل التعبئة الأمامية (Forward Fill) أو التقريب الزمني، كما تم استبعاد النقاط غير المتزامنة التي قد تؤثر على دقة التدريب [3][6]

إن اختيار هذا النوع المتنوع من البيانات يستند إلى دراسات سابقة أثبتت الأثر المباشر وغير المباشر لهذه المتغيرات على سعر الذهب [1][2][4][10]. ويسعى هذا التنوع في المصادر إلى تمكين النموذج من فهم العلاقات الاقتصادية المتداخلة، وتقديم تنبؤات دقيقة قابلة للتطبيق في بيئات مالية حقيقية.

4 التحليل الاستكشافي للبيانات

بني التحليل الاستكشافي في هذه الدراسة على استكشاف خصائص البيانات الأولية وتحليلها إحصائياً وبصرياً لفهم طبيعتها قبل تطبيق النماذج التنبؤية. تم تقسيم التحليل إلى قسمين رئيسيين: تحليل البيانات اليومية وتحليل البيانات الساعية، بهدف التحقق من الفروق السلوكية للترددتين الزمنيين، وتحديد التحديات الكامنة في كل منهما.

أولاً، أظهرت الإحصائيات الوصفية للبيانات اليومية أن متوسط سعر إغلاق الذهب كان مستقرًا نسبيًا على المدى الطويل، مع وجود اتجاه تصاعدي تدريجي يتوافق مع الأزمات الاقتصادية العالمية (مثل جائحة كورونا وارتفاع التضخم بعد 2020). كما أظهر الانحراف المعياري تذبذبًا معتدلاً يشير إلى تقلبات دورية، في حين أظهرت بعض النقاط قيمًا شاذة ناتجة عن اضطرابات السوق قصيرة المدى، تم رصدها بصرياً عبر مخططات الخط الزمني ومربعات Box Plot.

أما البيانات الساعية، فقد كشفت عن تذبذبات أكثر حدة بسبب الطبيعة اللحظية للتغيرات، حيث تراوحت تقلبات الأسعار ضمن اليوم الواحد بمعدلات أعلى نسبيًا. وقد ظهر ذلك بوضوح في الرسوم البيانية التي أظهرت أنماطاً موسمية على مستوى الساعات، وهو ما يُعد مهماً في نمذجة السلاسل الزمنية قصيرة المدى [5][8]

تم أيضاً فحص العلاقات بين المتغيرات من خلال مصفوفات الارتباط (Correlation Matrix) وقد تبين أن سعر الذهب يرتبط ارتباطاً طردياً قوياً مع أسعار المعادن الأخرى مثل الفضة والبلاطين [4]، بينما أظهر ارتباطاً عكسياً واضحاً مع مؤشر الدولار الأمريكي (USDX) ، وهو ما يتفق مع الأدبيات الاقتصادية التي تعتبر الذهب والدولار أصلين متقابلين في السيولة العالمية [1]. كما أظهرت بعض المؤشرات مثل VIX (مؤشر الخوف) ارتباطاً إيجابياً بسعر الذهب في فترات الأزمات، مما يعكس التوجه العام للمستثمرين نحو الأصول الآمنة. [2]

عند مقارنة البيانات اليومية بالبيانات الساعية، يظهر تباين واضح في طبيعة العلاقات بين المتغيرات، إذ تعكس البيانات اليومية الاتجاهات العامة وطويلة الأجل بدقة، بينما تُظهر البيانات الساعية ديناميكيات السوق اللحظية والأنماط الموسمية القصيرة، مثل تأثير جلسات التداول الأمريكية والأسبوعية. وقد ساهم هذا التباين في إبراز أهمية تضمين مؤشرات التحليل الفني قصير الأجل في النماذج المبنية على التردد الساعي، وذلك بخلاف النهج التقليدي الذي يركز غالباً على المتوسطات والانحرافات الكلية فقط. [7]

علاوة على ذلك، تم تحليل القيم المفقودة، حيث أظهرت البيانات اليومية فجوات زمنية ناتجة عن عطلات الأسواق، في حين ظهرت في البيانات الساعية فجوات في فترات الليل أو نهاية الأسبوع. وقد تم التعامل مع هذه القيم المفقودة بشكل مناسب باستخدام طرق تعويض مختلفة مثل التعبئة الأمامية، والانحدار الخطي، بناءً على ما أوصت به الدراسات الحديثة في مجال تعويض القيم المفقودة. [3]

يساهم هذا التحليل الاستكشافي في توجيه اختيار الميزات المناسبة لكل تردد زمني، وفهم طبيعة التفاعلات بين المتغيرات، والتأكد من جاهزية البيانات لتغذية النماذج التنبؤية ضمن بيئة خالية من التشويش أو الانحرافات.

5 المعالجة المسبقة واختيار الميزات

شهدت البيانات المستخدمة في هذه الدراسة عدداً من التحديات الفنية والبنوية التي تطأبت تنفيذ سلسلة من عمليات المعالجة المسبقة الدقيقة، وذلك لضمان جودة البيانات وتهيئتها بالشكل الأمثل قبل إدخالها في نماذج التعلم الآلي. وتنوعت هذه التحديات بين وجود القيم المفقودة، وتفاوت الترددات الزمنية بين مصادر البيانات، وتباين المقاييس العددية، إضافةً إلى الحاجة لاشتقاق ميزات فنية وزمنية تُعزّز قدرة النماذج على التعلّم.

فيما يخص القيم المفقودة، فقد ظهرت بشكل واضح في البيانات اليومية نتيجة لعطلات الأسواق، وفي البيانات الساعية بسبب فترات التوقف الليلي أو نهايات الأسبوع. للتعامل مع هذه المشكلة، تم اعتماد استراتيجية تعبئة متدرجة شملت التعبئة الأمامية (Forward Fill) واحتساب المتوسط الزمني، مع استبعاد الصفوف ذات النقص الحاد خصوصاً في البيانات الساعية نظراً لحساسيتها الشديدة للتغير اللحظي. وقد أكدت دراسة [3] Alrawajfi et al. (2024) أن اختيار الطريقة المناسبة لتعويض القيم المفقودة يمثل عاملاً حاسماً في تحسين أداء النماذج، خاصة عند التعامل مع بيانات زمنية ذات تكرار عالٍ.

كما جرى توحيد الإطار الزمني للبيانات المستوردة من مصادر مختلفة باستخدام تقنية إعادة التعيين الزمني (resampling)، وهو ما أتاح مزامنة السلاسل الزمنية المختلفة ضمن تردد موحد (سواء يومي أو ساعي). وقد نُبّهت الدراسات إلى أن هذا التوحيد لا يساهم فقط في تحسين الاتساق البنوي للبيانات، بل يحدّ من مخاطر التسريب الزمني التي تُعدّ من أبرز مصادر الخطأ في النماذج التنبؤية للبيانات المالية، كما أشار [6] Liu & Chen (2020).

ومن ناحية أخرى، ولتقليل أثر اختلاف المقاييس بين المتغيرات، خاصة في النماذج الحساسة مثل Ridge وLasso، تم تطبيق التحجيم القياسي باستخدام StandardScaler، حيث جرى تحويل جميع السمات الرقمية إلى توزيعات موحّدة ذات متوسط صفري وانحراف معياري يساوي واحد، بما يضمن اتزان الأوزان الناتجة وتجنّب انحرافات التعلّم. وتدعم هذه الخطوة الممارسات الموصى بها في دراسات مثل [1] Sami & Junejo (2017) التي أوضحت أهمية المعالجة المعيارية في النماذج الخطية.

لم تقتصر المعالجة على التنظيم والتوحيد فحسب، بل امتدت إلى مرحلة اشتقاق ميزات جديدة من البيانات الخام بهدف تعزيز قدرة النماذج على تمثيل العلاقات المعقدة. تم تطوير دالة مخصصة لاشتقاق مجموعة غنية من المؤشرات الفنية والزمنية، شملت أبرز أدوات التحليل الفني مثل المتوسطات المتحركة (SMA) و(EMA)، ومؤشر القوة النسبية (RSI)، ومؤشر متوسط المدى الحقيقي (ATR)، ومؤشر الاتجاه المتوسط (ADX)، ومؤشر تدفق الأموال (MFI). وقد تم اختيار هذه المؤشرات بعناية لما لها من أهمية مثبتة في الكشف عن الزخم السعري، وقوة الاتجاه، والتذبذب في أسواق المعادن الثمينة، كما ورد في [7] Patel et al. (2021) و[2] Masud et al. (2025).

كما تم إدراج ميزات تأخيرية (Lag Features) مثل gold_close_lag1 وRSI_7_lag1، وهي تمثل القيم السابقة للمتغيرات الأساسية، وتُستخدم بشكل واسع في نمذجة العلاقات الزمنية لكونها تتيح للنماذج استيعاب تأثير الأحداث السابقة على القيم المستقبلية. وقد بينت دراسات مثل [23] Weng et al. [5] أن إدراج هذه الميزات يعزز الدقة التنبؤية، خاصة في البيانات الساعية المعرضة لتقلبات لحظية.

بعد اكتمال بناء مصفوفة الميزات، جرى تنفيذ عملية اختيار للسمات الأكثر أهمية باستخدام تقنيتين متكاملتين: الأولى تعتمد على خوارزمية SelectKBest المرتبطة باختبار F-statistic لتقييم الارتباط الخطي بين كل سمة والمتغير الهدف، والثانية تعتمد على قياسات أهمية الميزات (Feature Importance) المستخرجة من نموذج XGBoost، والتي تقيس مدى مساهمة كل سمة في تقليل الخطأ الكلي. وقد أتاح تقاطع نتائج الطريقتين الوصول إلى مجموعة ميزات نهائية تجمع بين الارتباط الإحصائي العالي والتأثير العملي المباشر على أداء النموذج، كما هو موصى به في [4] Das et al. (2022).

وأخيراً، لضمان نزاهة التقييم ومنع تسرب المعلومات (Data Leakage)، تم تنفيذ جميع عمليات المعالجة داخل بيئة زمنية معزولة، بحيث يتم تطبيقها فقط على بيانات التدريب دون أن تتأثر بها مجموعة الاختبار النهائية، وهو ما يشكل عنصراً أساسياً في بناء تجارب موثوقة ومعقدة، وأكد ذلك Liu & Chen [6] (2020) في دراستهم حول منع التسريب الزمني في نماذج التنبؤ المالي.

تُعد هذه المرحلة من أهم مراحل المشروع، إذ إنها لا تضمن فقط نظافة البيانات واتساقها، بل تُسهم بشكل فعال في تعزيز الأداء التنبؤي للنماذج، وتمكينها من استيعاب الأنماط المعقدة في حركة أسعار الذهب على الترددات الزمنية المختلفة.

6 النماذج والتجارب

سعيًا لبناء نموذج تنبؤي موثوق لسعر إغلاق الذهب، تم اعتماد مجموعة من نماذج التعلم الآلي التي تمثل مدارس مختلفة من حيث البنية والآلية، بدءاً من النماذج الخطية الكلاسيكية، مروراً بالنماذج المنتظمة، ووصولاً إلى النماذج التجميعية والمعززة. جاء هذا التنوع في النماذج مدعوماً بما أورده الأدبيات السابقة حول قدرة هذه النماذج على التعامل مع بيانات زمنية مالية معقدة ومتغيرة، لاسيما في مجال تنبؤ أسعار الذهب [2][4][7].

تم اعتماد الانحدار الخطي (Linear Regression) كنموذج خط أساس baseline لما يتمتع به من شفافية في التفسير وسهولة في التهيئة، وهو ما أوصت به دراسات عديدة كإحدى خطوات تحليل العلاقات الأولية بين الميزات والسعر المستهدف [1]. تم لاحقاً تحسين هذا النموذج باستخدام خوارزمية اختيار الميزات التكراري RFE، كما تم تطبيق نماذج Ridge، Lasso، وElastic Net، والتي تسمح بفرض نوع من التنظيم الإحصائي للحد من تأثير التعدد الخطي وفراط التعلّم، وهي مشكلة شائعة في بيانات الذهب متعددة المصادر. [6]

بالتوازي، تم اختبار نموذج XGBoost نظراً لما أثبتته دراسات عديدة حول كفاءته العالية في التنبؤ بالسلاسل المالية غير الخطية والمعقدة [2][7]. كما جرى تضمين نموذج Polynomial Regression لتحليل العلاقات من الرتب الأعلى، ونموذج Stacking Regressor الذي يُعدّ من النماذج التجميعية التي

تستفيد من تكامل النماذج المختلفة ضمن هيكل موحد. وقد أوصت بعض الأبحاث باستخدام هذا النوع من التجميع لتعزيز دقة النماذج عند وجود تباين سلوكي بين المتغيرات.[4]

تم تقسيم البيانات زمنيًا إلى مجموعات تدريب وتحقق واختبار، مع مراعاة الفصل الزمني الكامل لتجنب التسريب، وهي ممارسة أكدت عليها دراسات مثل [6] (Liu & Chen (2020) لتفادي تقييمات مضللة في النماذج التنبؤية.

على صعيد البيانات اليومية، أظهر نموذج الانحدار الخطي المحسن بـ RFE أفضل أداء تنبؤي، حيث سجل $R^2 = 0.9953$ ، $MAE = 14.95$ ، وهو ما يعكس بساطة العلاقات في هذا التردد الزمني، وتجانس الإشارات الاقتصادية طويلة المدى. تبعه نموذج Ridge، ثم Lasso، بنتائج متقاربة. على النقيض، أظهر نموذج XGBoost أداءً مفرطًا على بيانات التدريب مع انهيار في بيانات الاختبار ($R^2 = -0.8071$)، مما يشير إلى فرط تعلم واضح، وهو تحدٍ معروف في النماذج المعززة عندما لا تتم موازنته بشكل جيد [8]. كما أن نموذج Polynomial فشل في التكيف مع التوزيع الواقعي للبيانات، حيث أعطى تنبؤات خارجة عن النطاق المقبول.

أما في البيانات الساعية، فقد تغير سلوك النماذج بشكل ملحوظ بسبب ارتفاع التذبذب اللحظي، وهو ما تؤكد دراسات مثل Weng et al. (2023) حول صعوبة التنبؤ بالسلاسل الساعية مقارنة بالبيانات اليومية [5]. في هذا السياق، تصدر نموذج Linear_RFA النتائج محققًا $R^2 = 0.9925$. كما حافظ نموذج ElasticNet على أداء قوي نسبيًا، بينما استمر XGBoost في تسجيل أداء ضعيف جدًا على بيانات الاختبار ($R^2 = -16.94$)، وهو ما يعكس عدم استقراره في التعامل مع الضوضاء اللحظية، كما أشار [8] Chandar et al. (2024).

تكشف هذه التجارب أن الأداء التنبؤي للنموذج يتأثر بشكل كبير بالتردد الزمني للبيانات؛ حيث تكون النماذج الخطية المنتظمة مناسبة للبيانات اليومية التي تعكس اتجاهات عامة، في حين تتطلب البيانات الساعية نماذج مرنة تتحمل التقلبات اللحظية دون الإفراط في التعلم. كما أثبت نموذج Stacking فعاليتها في كلا السياقين، مما يؤيد فكرة دمج النماذج (model ensembling) كاستراتيجية عامة لتحسين الأداء [4][7]

وأخيرًا، تؤكد هذه التجارب أن النماذج البسيطة قد تتفوق في الأداء على النماذج المعقدة إذا ما تمت معالجتها وتكييفها بشكل صحيح مع طبيعة البيانات، وهو ما يتماشى مع توصيات الأدبيات التي دعت إلى تكييف النموذج مع خصائص المشكلة بدلاً من الاعتماد على التعقيد كنقطة قوة بحد ذاته [1][6]

7 تحليل النتائج

أظهرت التجارب المقارنة للنماذج المستخدمة في هذه الدراسة تباينًا ملحوظًا في الأداء، سواء بين النماذج نفسها أو بين نوعي البيانات (اليومية والساعية). وقد تم تقييم الأداء باستخدام ثلاث مؤشرات أساسية: متوسط الخطأ المطلق (MAE)، الجذر التربيعي للخطأ المتوسط (RMSE)، ومعامل التحديد (R^2)، وذلك لضمان تقييم شامل يعكس دقة النموذج وقوة تفسيره لتغيرات السعر.

فيما يخص البيانات اليومية، برز الأداء القوي للنماذج الخطية والمنظمة، وتحديدًا نموذج الانحدار الخطي المحسن باختيار الميزات (RFE)، حيث حقق أداءً متميزًا على مجموعة الاختبار ($MAE \approx 14.95$)، ($R^2 \approx 0.995$). ويؤكد هذا التفوق ما ورد في دراسة [1] Sami & Junejo (2017) التي أشارت إلى كفاءة النماذج الخطية في تحليل التأثيرات الاقتصادية المباشرة على سعر الذهب في حال تم تعزيزها بميزات مناسبة وتنظيم جيد.

نموذج Ridge مع RFE، بالإضافة إلى نموذج Stacking التجميعي، حققا أداءً مقاربًا، مما يعزز الرؤية التي قدمتها [7] Patel et al. (2021) حول فعالية النماذج المنظمة ودمج النماذج (Ensemble Learning) في التعامل مع البيانات المالية المعتمدة على مؤشرات متعددة.

في المقابل، أظهر نموذج XGBoost أداءً متذبذبًا، إذ كان ممتازًا على بيانات التدريب لكنه انهار عند الاختبار ($R^2 \approx -0.807$). هذا يتماشى مع نتائج [2] Masud et al. (2025) الذين أشاروا إلى أن هذه النماذج تحتاج إلى معالجة دقيقة لتجنب فرط التعلم، خاصة مع البيانات الأقل تقلبًا مثل البيانات اليومية.

أما نموذج الانحدار متعدد الحدود (Polynomial Regression)، فقد فشل في تمثيل العلاقة الحقيقية بين الميزات والسعر، مما أدى إلى تنبؤات خارجة عن النطاق المقبول، وهو ما يعكس محدودية هذا النموذج عند التعامل مع بيانات مالية تحتوي على ضوضاء.

في حالة البيانات الساعية، ازدادت التحديات بسبب التذبذب اللحظي وسرعة التغيرات. رغم ذلك، تمكن نموذج Linear Regression مع RFE من تحقيق نتائج ممتازة ($R^2 \approx 0.992$ ، $MAE \approx 6.5$)، يليه نموذج Stacking، ثم Ridge وElasticNet، مما يعكس قدرة هذه النماذج على التكيف مع الضوضاء اللحظية إذا ما تم دعمها بميزات دقيقة وتنظيف مناسب للبيانات.

هذه النتائج تتوافق مع ما أشار إليه [5] Weng et al. (2023) و [8] Chandar et al. (2024) حول أهمية استخدام نماذج مرنة ومدعومة بمؤشرات فنية في التعامل مع السلاسل الزمنية عالية التردد، والتي تتطلب فهمًا لحظيًا للأنماط الموسمية ضمن اليوم.

أما XGBoost فقد كرر فشله في هذه الحالة، محققًا $R^2 \approx -16.94$ ، وهو ما يعكس عدم ملاءمته للبيانات التي تتطلب استجابة سريعة لتغيرات دقيقة، كما أشار إليه [6] Liu & Chen (2020) فيما يخص ضعف النماذج المعززة في الحالات ذات التكرار الزمني الضيق وفجوات التوقيت الدقيقة.

كان لاشتقاق المؤشرات الفنية مثل RSI وSMA وATR، بالإضافة إلى ميزات التأخير (Lag Features)، دور محوري في تعزيز أداء النماذج المنظمة، حيث أظهرت الدراسات مثل [4] Das et al. (2022) أهمية هذه الميزات في كشف الزخم السعري والاتجاهات قصيرة الأمد، خاصة في الأسواق ذات التذبذب العالي مثل الذهب.

تؤكد نتائج هذه الدراسة أن النماذج البسيطة، حين تُبنى على أسس معالجة قوية وميزات مختارة بعناية، يمكن أن تتفوق على النماذج المعقدة مثل XGBoost. كما تؤكد الحاجة إلى تكيف النموذج مع طبيعة البيانات والتردد الزمني، بدلاً من الاعتماد الأعمى على النماذج الرائجة في الأدبيات، وهي نقطة سبق التنبيه لها في الأعمال السابقة مثل [2][4][7].

8 المقارنة مع الدراسات السابقة

تُظهر هذه الدراسة تقاطعات واضحة مع الأدبيات الحديثة من جهة، وتقدم في الوقت ذاته عددًا من الإضافات المنهجية التي تسهم في معالجة جوانب لم تُعطَ حقها في أعمال سابقة.

فعلى صعيد التردد الزمني، ركزت معظم الدراسات السابقة على البيانات اليومية أو الشهرية فقط، دون أن تتناول البيانات الساعية أو اللحظية. وهنا تبرز إضافة نوعية للدراسة الحالية، إذ قامت بتحليل أسعار الذهب على مستويين زمنيّين مختلفين — اليومي والساعي — بهدف فحص قدرة النماذج على التكيف مع كل تردد وظروفه الخاصة. هذا الجانب نادر التداول في الأدبيات، رغم أهميته المتزايدة في ظل انتشار التداول عالي التردد (High-Frequency Trading)، كما أشار إليه [5] Weng et al. (2023).

أما من حيث النماذج، فقد أشادت بعض الدراسات، مثل Masud et al. (2025) و Das et al. (2022)، بقدرة نماذج التعلم المعزز (مثل XGBoost) على تمثيل العلاقات غير الخطية والتكيف مع البيانات المعقدة [2][4]. إلا أن نتائج دراستنا تشير إلى عكس ذلك تمامًا في سياق البيانات الذهبية، إذ أظهر XGBoost أداءً ضعيفًا جدًا على مجموعة الاختبار في كلا الترددين، رغم نتائجها الجيدة ظاهريًا على بيانات التدريب. هذا يعكس مشكلة فرط التعلم (Overfitting) الحاد، وهو ما يبرز أهمية تقييم النموذج ليس فقط على نتائج التدريب بل على بيانات لم تُر سابقًا (Validation & Test)، كما تم الالتزام به بدقة في هذه الدراسة.

في المقابل، تفوقت النماذج الخطية المنظمة، مثل Ridge و ElasticNet و Lasso، خاصة عند دمجها مع تقنيات اختيار الميزات مثل RFE، حيث أظهرت نتائج مستقرة على كل من البيانات اليومية والساعية. هذه النتيجة تخالف ما ذهب إليه Chandar et al. (2024)، الذين اعتبروا النماذج الخطية غير ملائمة لبيئات السوق المتقلبة، ما يدل على أن فعالية هذه النماذج تعتمد بدرجة كبيرة على جودة المعالجة المسبقة وثراء الميزات [8].

من الناحية المنهجية، تختلف هذه الدراسة عن معظم الأعمال السابقة في حجم وتنوع الميزات المدخلة. فبينما اقتصرت دراسات سابقة على مؤشرات أساسية مثل أسعار العملات أو النفط، قامت دراستنا بدمج طيف واسع من المؤشرات الفنية والمالية، شملت المعادن النفيسة، مؤشرات الأسهم، مؤشرات التقلب، وأسهم شركات تعدين الذهب، فضلًا عن اشتقاق فنية متعددة مثل RSI، MFI، SMA، وغيرها. هذا الدمج الشامل ساعد في تعزيز الأداء التنبؤي للنماذج، خصوصًا النماذج المنظمة.

أخيرًا، تميزت هذه الدراسة بالالتزام الصارم بمنهجية تجريبية دقيقة، تضمنت الحفاظ على الترتيب الزمني للبيانات، تجنب التسريب الزمني، وتطبيق خطوات معالجة مسبقة مصممة خصيصًا لكل تردد زمني. كثير من الدراسات الأخرى تهتم فقط بإبراز النتائج الرقمية دون توضيح السياق التحليلي أو العمليات المسبقة التي قد تؤثر على دقة التقييم.

بذلك، لا يمكن اعتبار هذه الدراسة مجرد تكرار للدراسات السابقة، بل هي خطوة تكاملية تُعيد تقييم الفرضيات المتداولة في الأدبيات، وتقدم منظورًا أكثر واقعية وصرامة لتطبيقات التعلم الآلي في التنبؤ بأسعار الذهب.

9 الخلاصة والتوصيات

تهدف هذه الدراسة إلى بناء إطار تنبؤي دقيق ومرن لسعر إغلاق الذهب، من خلال تحليل بيانات مالية واقتصادية باستخدام تقنيات تعلم آلي متعددة، وعلى ترددين زمنيّين مختلفين: يومي وساعي. وقد ارتكز النهج المتبع على معالجة متقدمة للبيانات، شملت دمج مصادر متنوعة مثل أسعار العملات، مؤشرات الأسهم العالمية، أسعار النفط، المعادن الأخرى، وأسهم شركات تعدين الذهب، مع اشتقاق مجموعة من الميزات الفنية والزمنية مثل المتوسطات المتحركة ومؤشرات الزخم وميزات التأخير الزمني.

من خلال تجريب عدد من نماذج الانحدار المختلفة، بيّنت النتائج أن أداء النماذج يختلف باختلاف التردد الزمني المستخدم. ففي البيانات اليومية، حقق نموذج "Linear Regression with RFE" أداءً ممتازًا على مجموعة الاختبار، حيث وصل معامل التحديد (R^2) إلى 0.9953، وحقق قيمًا منخفضة لكل من MAE و RMSE. كما أظهرت نماذج مثل Ridge و Stacking نتائج مقاربة، مع ثبات واستقرار ملحوظ في الأداء. بالمقابل، أظهر نموذج XGBoost ضعفًا كبيرًا في الأداء على البيانات اليومية، حيث سجّل R^2 سلبيًا، مما يشير إلى فرط التعلم على بيانات التدريب وضعف التعميم.

أما في البيانات الساعية، فقد حافظ نموذج الانحدار الخطي (Linear Regression) على أدائه الجيد، محققًا R^2 تجاوز 0.99 في معظم الحالات، مع أداء ممتاز على كل من مجموعة التحقق والاختبار. كما أثبتت نماذج Ridge و ElasticNet و Stacking فعاليتها في التردد الساعي، بينما تراجع أداء XGBoost بشكل كبير، مسجلًا قيم خطأ مرتفعة جدًا على بيانات الاختبار ($MAE > 500$)، مما يؤكد حساسيته العالية للتقلب اللحظي في البيانات الساعية.

ساعدت عمليات المعالجة المسبقة الدقيقة، مثل معالجة القيم المفقودة وتوحيد التردد الزمني للمصادر المختلفة، في تقليل التشويش وضمان جودة البيانات الداخلة للنماذج.

توصيات الدراسة:

على المستوى التطبيقي يُوصى باستخدام نموذج الانحدار الخطي المحسن بـ RFE أو نموذج Ridge عند التعامل مع بيانات يومية أو ساعية، نظرًا لما أظهره من استقرار عالٍ ودقة جيدة مع قابلية تفسير ممتازة.. أما بالنسبة للبيانات الساعية لا يُنصح باستخدام نماذج XGBoost في شكلها التقليدي نظرًا لتدهور الأداء، بل يُقترح التوجه نحو نماذج تسلسلية مثل LSTM أو Transformer القادرة على تمثيل السياق الزمني اللحظي بدقة أكبر.

من الناحية البحثية: تقترح الدراسة تحسين التنبؤ ليشمل معرفة السعر بشكل لحظي أو تحويل مشكلة التنبؤ إلى مسألة تصنيف، مثل تصنيف اتجاه السعر (صعود/هبوط)، أو تحديد نطاق السعر، ما يفتح آفاقًا جديدة للتطبيقات العملية. و **على صعيد تطوير البيانات** يُستحسن توسيع قاعدة البيانات لتشمل متغيرات أنية مثل العملات المشفرة، مؤشرات التضخم، والبيانات الاقتصادية الدقيقة، مما يزيد من قدرة النماذج على التكيف مع التغيرات العالمية السريعة.

ختامًا، تبرز أهمية الجمع بين المعالجة الذكية للبيانات، واختيار الميزات بعناية، وتحديد النموذج الملائم حسب طبيعة التردد الزمني، كعوامل حاسمة لبناء أنظمة تنبؤ ذكية وفعالة في أسواق الذهب الديناميكية.

10 المراجع

1. Sami, L., & Junejo, K. (2017). Predicting Gold Prices Using Regression Analysis. *Journal of Financial Analytics*, 12(2), 45-56.
2. Masud, M., Rahman, M., & Hossain, M. (2025). A Hybrid Deep Learning Framework for Gold Price Forecasting. *Expert Systems with Applications*, 207, 117899.
3. Alrawajfi, M., Zain, J. M., & Omar, K. (2024). Handling Missing Values in Time Series Gold Price Data: A Comparative Study. *International Journal of Data Science*, 8(1), 101-115.
4. Das, S., Saha, S., & De, D. (2022). A Survey on Machine Learning Techniques in Gold Price Prediction. *Journal of Economic Computation*, 15(3), 144–160.
5. Weng, H., Zhang, L., & Wu, Y. (2023). Modeling High-Frequency Gold Price Movements using Deep Learning. *Neural Computing and Applications*, 35(14), 10091–10104.
6. Liu, Y., & Chen, T. (2020). Preventing Data Leakage in Financial Forecasting Models. *Journal of Data Integrity*, 4(3), 233-245.
7. Patel, J., Shah, S., Thakkar, P., & Kotecha, K. (2021). Predicting Gold Prices with Ensemble Learning and Feature Engineering. *Procedia Computer Science*, 192, 689–697.
8. Chandar, R., Reddy, P., & Kumar, V. (2024). LSTM Networks for Gold Price Forecasting in High-Frequency Markets. *IEEE Access*, 12, 55987–55996.
9. Khan, N., & Naeem, M. (2023). Evaluation Metrics for Regression-Based Economic Forecasting. *Journal of Applied Economics*, 29(1), 112–130.

10. Wang, L., Li, X., & Hu, Z. (2021). Enhancing Gold Price Forecasting Using Multi-Source Economic Indicators. *Journal of Forecasting and Strategy*, 28(4), 225–240.
11. Yahoo Finance. (2025). Gold historical hourly and daily data. Retrieved from <https://finance.yahoo.com/quote/GC%3DF/history/>
12. Yahoo Finance. (2025). Currency exchange rates (EUR/USD, USD/JPY, GBP/USD, CNY/USD, INR/USD). Retrieved from <https://finance.yahoo.com/currencies>
13. Yahoo Finance. (2025). Oil and Metals (WTI, Brent, Silver, Platinum). Retrieved from <https://finance.yahoo.com/commodities>
14. Yahoo Finance. (2025). Global indices (S&P500, NASDAQ, DOW JONES, FTSE, DAX, NIKKEI). Retrieved from <https://finance.yahoo.com/world-indices>
15. Yahoo Finance. (2025). Gold mining companies (WPM, EGO, BVN). Retrieved from <https://finance.yahoo.com/lookup>